



U-Net 리뷰



이희종



Introduction





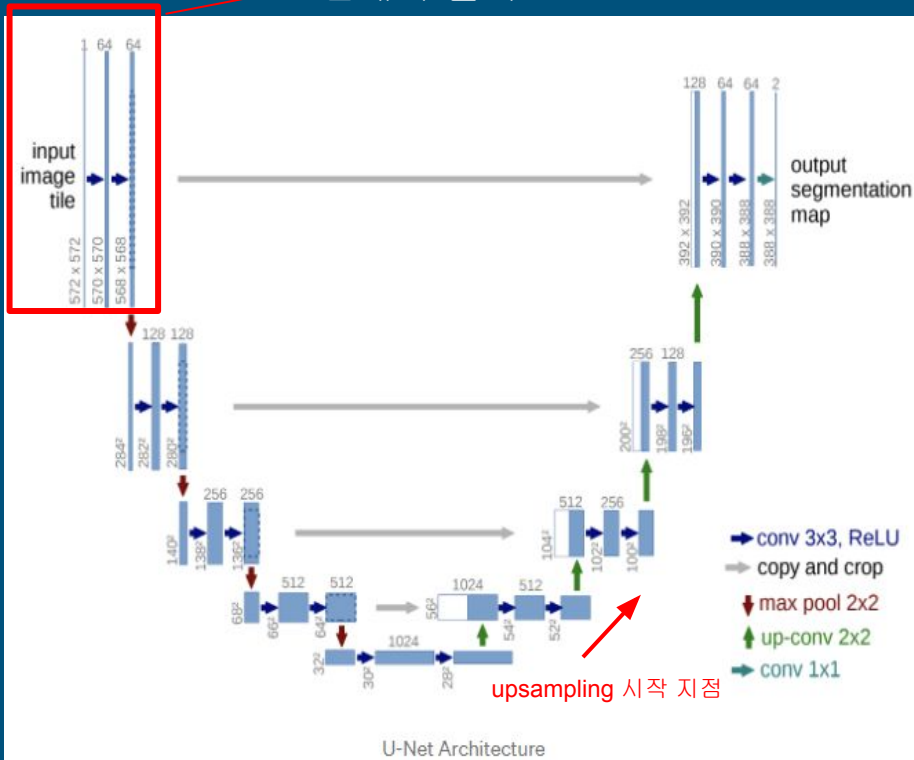
Figure 1. Semantic segmentation 예시



1. U-net은 기본적으로 FCN을 확장시킨 모델이다. (FCN은 semantic segmentation 과정에서 upsampling을 이용해서 Dense층을 사용하지 않게된 모델을 말한다.) 주요 개념은 downsampling(contracting path - 왼쪽) 과 upsampling(expansive path - 오른쪽)을 해주는 방식이다.
2. 입력 이미지의 context를 포착하기 위한 목적으로 contracting path 형성 (왼쪽), 세밀한 localization을 위해서 expansive path 형성(오른쪽)
3. 이미지 분할을 더 잘하기 위해서 overlap-tile 전략을 사용했는데, 이것은 타일이 이동하면서 segmentation 하면서 여백으로 손실된 데이터가 있는 부분을 mirroring 해 데칼코마니 처럼 복제 해주는 것이다. 이 방법을 쓰면 GPU의 사용에 무리를 주지 않게 해준다.

Network Architecture

한개의 블록



1. 모델의 기본 구조는 우선 3x3의 커널을 가진 필터를 이용해 convolution layer를 두 번 거친다
2. 이후 Relu 활성화 함수를 사용해 값을 비선형적 구조로 만들어 준다.
3. 마지막으로 stride = 2와 2x2 필터로 max-pooling을 해준다.
4. 1~3의 방식이 하나의 블록을 형성하고 있고 5번째 블록 이후 동일한 방법으로 upsampling을 해준다.

Training

1. 확률적 경사하강법을 사용했다(전체의 데이터중 단 하나의 데이터를 사용해 경사하강법을 1회 진행하는 것이다. 즉 배치크기가 1이 된다. 이는 배치 경사하강법에 비해 적은 데이터로 학습가능하고 속도가 빠른 장점이 있다.)
2. 출력값은 픽셀단위의 softmax로 예측된다.
3. loss function은 cross-entropy 함수가 사용된다.

Data Augmentation

1. 데이터의 수가 적기 때문에 모델의 성능을 더욱 확고하게 만들어 주기 위해서 증강을 사용했다.
2. 증강 방법으로 여러가지가 있는데 우리가 흔히 알고 있는 **rotation**(회전), **shift**(반전)을 사용했다.
3. 위의 방법 외에도 **elastic deformation** 이라는 방법을 사용했는데 이는 원본 이미지를 일그러 뜨리는 이미지를 생성하는 증강 방식이다.

Conclusion

1. 여러가지 실험 결과 ISBI 대회(세포이미지를 분리하는 대회)에서 상당히 높은 결과를 보여주었다(약 77.5%로 다른 모델(최고 46%)에 비해 월등히 좋은 결과를 보여줌).
2. 위의 대회에서 충분히 좋은 성능을 보여주는 모델로서 이외에도 다른 생명공학, 의학 문제들을 해결할 수 있는 가능성을 보여주었다.
3. 이전의 모델들보다 학습 시간도 더 적게 사용함(U-net 으로 training 하는데 10시간 소요, 사용 GPU : NVidia Titan(6GB))